

## مقدمه

در این مقاله، یک مدل یادگیری مبتنی بر "هَب" (Hebbian) (learning) بررسی شده است که بر اساس زمان بندی دقیق اسپایک ها (spikes) عمل می کند. این مدل به جای تمرکز صرف بر نرخ فعالیت نورون ها، اطلاعات زمانی دقیق اسپایک ها را در بازه های میلی ثانیه ای تحلیل می کند. چنین رویکردی برای درک بهتر یادگیری و حافظه در سیستم های عصبی پیشنهاد شده است.

## مدل پیشنهادی

این مدل از سه بخش اصلی تشکیل شده است:

۱. پیش سیناپس: اسپایک های ورودی که از طریق وزن های سیناپسی بر یادگیری تأثیر می گذارند.
۲. پس سیناپس: اسپایک های خروجی که تغییرات سیناپسی را کنترل می کنند.
۳. وابستگی زمانی: تابعی که نشان می دهد چگونه زمان بندی دقیق اسپایک ها، همبستگی سیناپسی را تغییر می دهد.

معادله اصلی تغییرات سیناپس چنین است:

$$\Delta J_i(t) = \int_t^{t+T} [\text{win} \cdot S_{\text{in}}(t') + \text{wout} \cdot S_{\text{out}}(t')] dt' + \int_t^{t+T} \int_t^{t+T} W(s) S_{\text{in}}(t'') S_{\text{out}}(t') dt'' dt',$$

که در آن  $W(s)$  پنجره زمانی یادگیری و  $S_{\text{in}}$  و  $S_{\text{out}}$  اسپایک های ورودی و خروجی هستند.

## تحلیل ریاضی

برای تحلیل ساده تر این مدل، از روش های آماری و کانولوشن استفاده شده است:

۱. میانگین گیری از اسپایک ها: برای کاهش نویز و نوسانات، اسپایک ها در بازه های زمانی بزرگ تر میانگین گیری شده اند.
۲. تابع همبستگی: احتمال همزمانی اسپایک های ورودی و خروجی در زمان های مختلف با استفاده از تابع همبستگی محاسبه می شود:

$$C_i(s; t) = \langle S_{\text{in}}(t+s) S_{\text{out}}(t) \rangle.$$

۳. کانولوشن با پنجره یادگیری: همبستگی زمانی اسپایک ها با تابع پنجره  $W(s)$  ترکیب می شود:

$$\int_{-\infty}^{\infty} W(s) C_i(s; t) ds.$$

۴. معادله نهایی یادگیری: معادله تغییرات سیناپس به صورت زیر به دست می آید:

$$\frac{dJ_i(t)}{dt} = \text{win} \cdot \nu_{\text{in}}(t) + \text{wout} \cdot \nu_{\text{out}}(t) + \int_{-\infty}^{\infty} W(s) C_i(s; t) ds,$$

که  $\nu_{\text{out}}$  و  $\nu_{\text{in}}$  نرخ میانگین اسپایک های ورودی و خروجی هستند.

## محدودیت‌های مدل‌های مبتنی بر نرخ

مدل‌های مبتنی بر نرخ چند محدودیت کلیدی دارند:

۱. **بازه‌های زمانی طولانی:** این مدل‌ها برای بازه‌های زمانی بلند (چند صد میلی ثانیه) طراحی شده‌اند، اما یادگیری واقعی ممکن است در بازه‌های کوتاه رخ دهد.
۲. **نادیده گرفتن اطلاعات دقیق زمانی:** این مدل‌ها اطلاعات زمانی دقیق اسپایک‌ها را که برای فرآیندهای عصبی مهم هستند، حذف می‌کنند.
۳. **پیچیدگی بالای سیستم‌های واقعی:** مدل‌های مبتنی بر نرخ نمی‌توانند پیچیدگی یادگیری در سیستم‌های عصبی واقعی را به خوبی نشان دهند.

مدل پیشنهادی با تمرکز بر زمان‌بندی دقیق اسپایک‌ها تلاش می‌کند این محدودیت‌ها را برطرف کند و دیدگاه جدیدی به یادگیری سیناپسی ارائه دهد. برای بررسی معادله‌ی مدل پیشنهادی یکی از نکات لازم، دانستن نوع همبستگی بین نورون‌ها (تابع همبستگی  $C_i$ ) است؛ که بدست آوردن معادله‌ی یادگیری‌ای قابل حل، به آن وابسته است. در انتهای این بخش این معادله را بدست خواهیم آورد و برای این کار ناچاریم وارد جزئیات ریاضیاتی شویم. خلاصه سازی این جزئیات موجب سخت تر شدن فهم آنها می‌شود. میتوانید صرفاً فرم معادله را پذیرفته و نتایج شبیه سازی با آن را مطالعه کنید. در این صورت از این بخش گذر کنید؛

مدل:

نورونی را در نظر بگیرید که  $N$  ورودی، تصادفی و مستقل از هم، از نورون‌های دیگر دریافت میکند؛ خروجی این نورون نیز  $N$  خروجی تصادفی خواهد بود. و ورودی سیناپس  $i$ ام، نرخ تیزه زدن نورون را به شکل زیر افزایش و کاهش خواهد داد. تصور شده است که نورون، ورودی‌ها را خطی با هم جمع و یا از هم کم میکند:

$$\lambda^{\text{out}}(t) = \nu_0 + \sum_{i=1}^N \sum_f J_i(t_f^i) \epsilon(t - t_f^i).$$

و چون در معادله‌ی یادگیری به میانگین آنزامل‌ها علاقمندیم:

$$\langle S^{\text{out}}(t) \rangle = \nu_0 + \sum_{i=1}^N J_i(t) \int_0^\infty ds \epsilon(s) \lambda_i^{\text{in}}(t - s).$$

که برای سادگی بخش دوم را اینگونه نشان میدهیم:

$$\Lambda_i^{\text{in}}(t) = \int_0^\infty ds \epsilon(s) \lambda_i^{\text{in}}(t - s).$$

در اینجا ممکن است برای خواننده‌ی دقیق شبه پیش بیاید که چرا  $J_i(t)$  در معادله ظاهر شده و مگر نباید این مقدار  $J_i(t+s)$  باشد؟ سوالی کاملاً به جا و در جواب لازم است نشان دهیم این دو مقدار برابرند. اما در اینجا به جزئیات آن نپرداخته‌ایم. // همچنین باید تابع کانولوشن را نیز تبیین کنیم. این تابع به شکل زیر خواهد بود:

$$Q_{ij}(t) := \int_{-\infty}^\infty ds W(s) q_{ij}(s; t).$$

که مقادیر  $q_{ij}$ ، یعنی همان ماتریس کواریانس، به شکل زیر خواهد بود:

$$q_{ij}(s; t) := [\Lambda_i^{\text{in}}(t + s) - \nu_i^{\text{in}}(t + s)][\Lambda_j^{\text{in}}(t) - \nu_j^{\text{in}}(t)].$$

و نهایتاً به کمک عبارات بالا، تابع همبستگی تعریف می‌شود:

$$C_i(s; t) = \sum_{j=1}^N J_j \Lambda_j^{\text{in}}(t + s) \Lambda_i^{\text{in}}(t) + \lambda_i^{\text{in}}(t + s) [\nu_0 + J_i(t) \epsilon(-s)].$$

و نهایتاً با جایگذاری تمامی این مقدار در رابطه‌ی یادگیری، بالاخره به معادله مورد نظر میرسیم:

$$J_i = w_i^{\text{in}} \nu_i^{\text{in}} + w^{\text{out}} \left[ v_0 + \sum_j J_j v_j \right] + \tilde{W}(0) \nu_i^{\text{in}} \nu_0 + \sum_j J_j \left[ Q_{ij} \nu_i^{\text{in}} \nu_j^{\text{in}} + \delta_{ij} \nu_i^{\text{in}} \int_{-\infty}^{\infty} ds W(s) e^{-s} \right],$$

با نامگذاری‌های جدید، معادله به فرم شکیل‌تر زیر درخواهد آمد:

$$J_i = k_1 + \sum_j [Q_{ij} + k_2 + k_3 \delta_{ij}] J_j,$$

که در آن مقادیر به شکل زیرند:

$$k_1 = [w^{\text{out}} + \tilde{W}(0) \nu_0] \nu^{\text{in}} + w^{\text{in}} \nu^{\text{in}},$$

$$k_2 = [w^{\text{out}} + \tilde{W}(0)] \nu^{\text{in}},$$

$$k_3 = \nu^{\text{in}} \int_{-\infty}^{\infty} ds W(s) e^{-s}.$$

در ادامه تمامی بررسی‌های ما روی این "مدل اسباب بازی" خواهد بود که رابطه‌ی مربوطه‌ی آن را بدست آوردیم. یعنی می‌خواهیم به سراغ این معادله برویم و با برخی ساده‌سازی‌ها، نتیجه‌ی این دینامیک را بررسی کنیم. در واقع سوال این است: آیا این دینامیک در کیس‌های ساده‌ای که جوابشان را بلدیم به نتیجه‌ی درستی میرسد؟  
ساده‌سازی‌ها:

۱.

$$K_3 = 0$$

۲. جمعیت نورونی ( $N$ ) را به دو گروه  $M_1$  و  $M_2$  تقسیم می‌کنیم. فرضیات زیر برای گروه‌ها برقرار است:

$$M_1 + M_2 = N, \quad M_1, M_2 \gg 1, \quad |M_1| = |M_2|$$

۳. ورودی نوفه‌ها را تابع توزیع پواسونی در نظر می‌گیریم که برای هر گروه متفاوت بوده به شکل زیر است:

| $M_2$                                      | $M_1$                                      |
|--------------------------------------------|--------------------------------------------|
| $\lambda_i^{in}(t) = \lambda^{in}(t)$      | $\lambda_i^{in}(t) = v^{in}$               |
| $\langle \lambda^{in}(t) \rangle = v^{in}$ | $\langle \lambda^{in}(t) \rangle = v^{in}$ |
| $Q_{ij}(t) = Q$                            | $Q_{ij} = 0$                               |

با این شرایط، سه ورودی مختلف برای بررسی پاسخ دینامیک داریم.

۱. نوبه سفید

۲. نوبه رنگین

۳. ورودی پریودیک

هر کدام از این ورودی ها تاثیر مختلفی بر پارامترهای مختلف مسئله و  $J, Q$  دارند که بهتر است در فاز بعدی پروژه دقیق تر به آنها بپردازیم. (به روش شبیه سازی عددی) نکته‌ی دیگری که در بررسی دینامیک یادگیری حائز اهمیت است؛ میانگین وزنی ( $J(averageweight)$ ) و میانگین خروجی ( $averageoutput$ ) است. انتظار داریم در مدت زمانی منطقی، این دو عدد به عددی میل کنند و واگرا نشوند. برای روش های دیگر مدلسازی یادگیری که این واگرایی اتفاق میافتد از روش های مختلفی مثل ری اسکیل کردن وزن ها، ثابت نگه داشتن جمع تمام وزن ها، و یا ثابت نگه داشتن جمع مجذور وزن ها استفاده می شود. و در این موارد مجبوریم پارامتر های معادله را تابعی از  $J$ ، در نظر بگیریم. اما در این روش مدلسازی نیازی به هیچکدام از قیدها نیست. چرا که دو پارامتر مورد نظر یعنی  $J^{avg}$  و  $v^{out}$  در طی فرایند یادگیری به یک نقطه‌ی پایدار میل میکنند.

$$J^{av} = \frac{1}{N} \sum_{i=1}^N J_i$$

با این وجود، می‌خواهیم حدی برای دو پارامتر مورد نظر بگذاریم (برای یک پارامتر به طور مستقیم در نظر میگیریم و برای پارامتر دیگر به طور غیر مستقیم اعمال می‌شود) با این کار سعی داریم مفهوم بیولوژیکی مسئله را حفظ کنیم. بدین معنا که پارامتر همبستگی نورنی مجهول نمیتواند بیشتر از مجموع  $N$  نورون باشد. این حد را به شکل زیر معرفی میکنیم:

و این حد قیودی بر پارامترهای دیگر می‌گذارد. که تاثیرش را در حل دینامیک خواهیم دید. اما خوب است در اینجا توقف کنیم و کمی به عقب برگردیم. باید بدانیم که بعد از چک کردن معادله در کیس های ساده و برقراری معادله در حدهای بالا و پایین؛ نهایتاً از این معادله، این دینامیک یادگیری، چه انتظاری داریم؟ اگر به ابتدای مقاله دقت کرده باشد این ایده مطرح می‌شود که در روش دینامیک یادگیری با سرعت‌های خیلی پایین تر از روش های دیگر سعی در بررسی مکانیزم یادگیری داریم؛ گویا مکانیزم یادگیری به تیزه‌زدن‌های نورون بستگی دارد. به بیان بهتر اردر زمانی مکانیزم یادگیری هم اردر است با تیزه زدن های نورون. پس سوال خود را در این مرحله اینگونه مطرح میکنیم:

**سرعت مکانیزم یادگیری چقدر است؟ از اردر تیزه‌زدن های نورون؟ کمتر؟ بیشتر؟**

برای پاسخ به این سوال دوباره به مثال جمعیت نورونی با دو گروه  $M_1$  و  $M_2$  برمیگردیم. این بار سعی داریم مقایسه‌ای بین دو گروه انجام دهیم و از این رو کمیته به نام  $J^{str}$  معرفی میکنیم. این کمیت سعی دارد همبستگی بین نورون‌های گروه  $M_1$  با خود را با گروه دیگر مقایسه کند. بر اساس محاسباتی که با این کمیت انجام میدهم میتوان کمیت دیگری را با توجه به این کمیت تعریف کرد. و این همان سرعت مکانیزم یادگیری را به ما خواهد داد. و نهایتاً پی میبریم که – حداقل در این رژیم ساده شده – سرعت مکانیزم یادگیری از اردر زمانی تیزه زدن بیشتر است. البته در تمام محاسبات این

قسمت از  $k_3$  صرف نظر کرده بودیم. میتوانیم آن را نیز به معادلات برگردانیم و با پیچیدگی بیشتری معادله را حل کنیم اما با ساده سازی هم توانستیم به جواب سوال خود برسیم. ساده سازی دیگری که تا اینجا به آن اشاره نکرده ایم وجود نویز است. به هنگام محاسبه ی وزن های میانگین، برای رسیدن به جوابی کلی و منطبق با شهود، از وزن های دقیق صرف نظر کرده و میانگین آنها را در نظر گرفتیم. اما حال وقت آن است که چک کنیم آیا این ساده سازی درست است؟ **تاثیر نویز و افت وخیز در پروسه ی یادگیری چقدر است؟** به بیانی تکنیکال تر، برای رندوم واکي که حول و حوش میانگین وزنی اتفاق می افتد؛ واریانس تعریف میکنیم.

$$var J_i(t)$$

با توجه به اینکه واریانس به طور خطی با پروسه ی یادگیری در حال افزایش است،  $t^{noise}$  را به آن منسوب میکنیم تا با مقایسه ی آن با  $t^{str}$  بتوانیم پاسخ سوال خود را بیابیم. در تعریف واریانس چهار ساده سازی را در نظر میگیریم:

۱. از حد بالا و پایینی که در محاسبات قبلی برای نرمالیزیشن بدست آورده بودیم صرف نظر میکنیم.
۲. از ارتباط بین دو تیزه زدن صرف نظر میکنیم؛ چرا که این فرض جمله ای ضعیف خواهد داد که تاثیرش را در  $K_3$  نشان میدهد و نیازی به بررسی آن در این حالت نیست.

$$\lambda_i^{in}(t) = v^{in} \quad \text{۳. ورودی را ثابت در نظر میگیریم.}$$

$$\lambda_i^{out}(t) = v^{out} \quad \text{۴. و چون ورودی را ثابت گرفتیم خروجی را نیز ثابت فرض میکنیم.}$$

و نهایتاً با محاسباتی که از جزئیاتش صرف نظر شده به این نکته میرسیم که هر همبستگی در ورودی، به شرطی که زمان کافی داشته باشد، میتواند یاد گرفته شود! اما نکته ی حائز اهمیت این است که با ری اسکیل کردن پارامتر ها (اضافه کردن قیدی بر پارامترها) میتوان زمان مورد نظر برای یادگیری را کنترل کرد (کاری که به نظر میرسد در سیستم های بیولوژیکی انجام میشود؛ یعنی با محدود کردن زمان یادگیری نویز را بی اثر کنیم!). و همین نکته برای صرف نظر از نویز با وارد کردن یک قید به مسئله کافیهست. در فاز بعدی پروژه به جزئیات این مسئله خواهیم پرداخت.